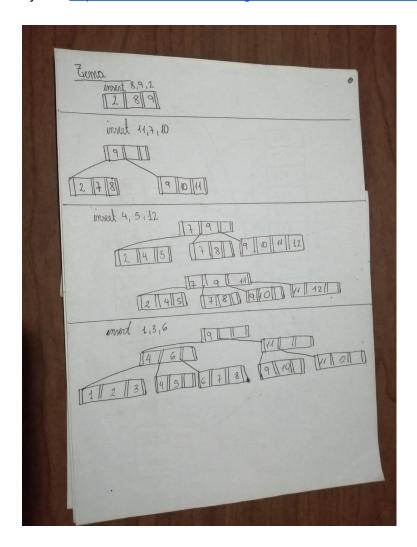
• RECOPILACIÓN PRIMER PARCIAL

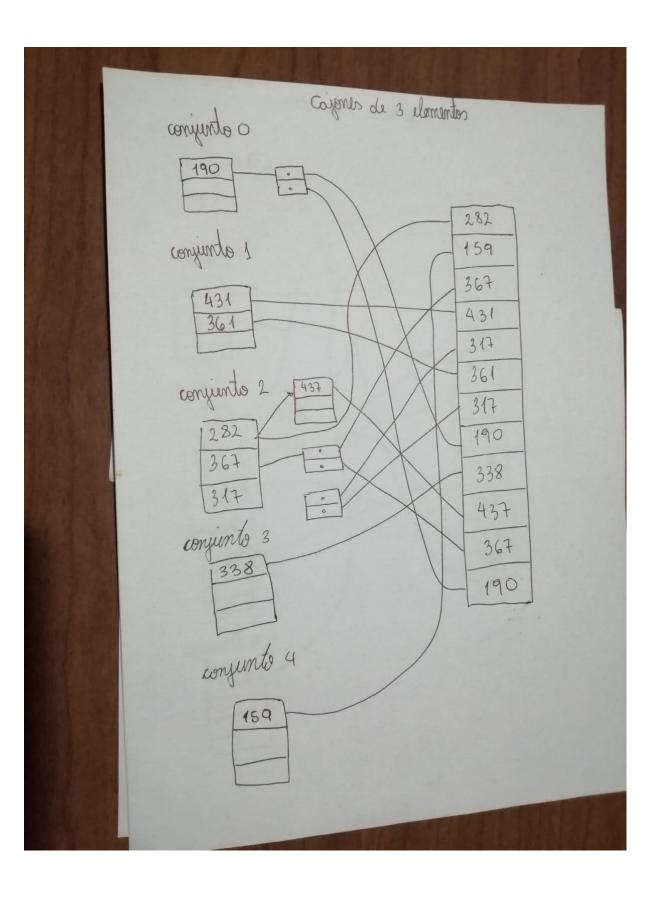
Conforme la siguiente tabla que corresponde al archivo de la relación EVALUACIÓN, en el que cada bloque del archivo corresponde a 1 fila, se pide:

- a- Construir un índice en forma de árbol B+ con nodos de 4 punteros para la clave primaria ID, suponiendo que los registros fueron ingresados (insertadas) según el orden de la columna NOMBRE.
- b- Construir un indice hash estático cerrado con cajones de 3 elementos cuya función de asociación es "x mod 5" sobre la columna PUNTAJE, siendo x el valor de cada fila en dicha columna.
- c- Explique para cada caso (a y b) anterior, si los registros indices apuntan o no a la tabla.

ID	NOMBRE	PUNTAJE
1	Preston Schwartz	282
2	Cathleen Steele	159
3	Tatyana Russo	367
4	Libby Madden	431
5	Orla Reid	317
6	Vivian Cherry	361
7	Kirk Jensen	317
8	Amanda Macias	190
9	Barry Morris	338
10	Lee Lopez	437
11	Elliott Fowler	367
12	Paula Johns	190

Ayuda: https://www.cs.usfca.edu/~galles/visualization/BPlusTree.html





Paro el arbo B+ (indice primario) Los registros indices opuntam a los registros de la table desde los modos hijos, pues para este caro el registro indice es el ID y montine la tabla ordinada. Para el indice harh (india seundaria) El par (puntero, clare) apunto o los rajones solonde se encuentran los registros y mo esto construidos solo minguno clara.

Explique en sus términos a que corresponde un índice y a que un archivo índice. Así mismo enumere al menos tres tipos de índices estudiados.

Los índices son aquellos que te ahorran tiempo en hacer una búsqueda en una colección basta de registros, por ej un índice de un libro nos puede guiar más rápidamente al cap que estamos buscando.

Los índices son estructuras de una base de datos utilizados para acelerar el acceso a los datos deseados.

Índices ordenados:

Son aquellos en donde los registros índice son almacenados según el orden definido por la clave de búsqueda, por lo tanto son archivos ordenados siempre.

Índices asociativos:

Son los que los registros índice son almacenados en un cajón partir del uso de una función de hash o de asociación.

Indices bitmap:

Estos índices están diseñados para consultar eficientemente con múltiples claves, siempre y cuando haya un índice bitmap en cada atributo. Este está compuesto por un array de bits para cada valor de atributo del índice.

Explique en sus términos las formas organización de archivos en posibles para la implementación de archivos de tablas/datos.

Explique las formas de organización física de los archivos de datos en un SGBD.

Los archivos se pueden organizar de cuatro maneras

Montículo(heap): Son los que se colocan en cualquier registro en cualquier parte del archivo en el que haya espacio, por esta razón estos no están ordenados. Para consultas aleatorias.

Secuencial: Son los que se guardan en orden secuencial según su valor de la clave de búsqueda de cada uno de ellos. Para consultas de tipo tipo de rango.

Hash: Es el cual se tiene por algún atributo del registro una función asociativa para la cual está indicará en qué bloque se encuentra el archivo, sirve también para colocar a los archivos que se van ingresando. Para consultas de tipo unitarias (una sola fila).

En agrupación: Tiene la particularidad que en él se guardan los datos de diferentes relaciones, también los registros relacionados se guardan en el mismo bloque. Para consultas de tipo join.

El que siempre va a funcionar es el secuencial.

Explique las medidas de rendimiento que deben tener en cuenta para la elección de unidades de discos magnéticos. ¿A su criterio, cuál de las mismas sería la más determinante?

Tiempo de acceso:

Tiempo que llega a leer o escribir datos desde su petición hasta su confirmación.

Tiempo de búsqueda:

Tiempo que tarda en ubicar el peine en la pista correcta. Al tener un disco más grande este puede tardar más tiempo en encontrar la pista a la cual está el dato que busca (los discos más pequeños tienen la ventaja que pueden tardar menos tiempo).

Latencia rotacional:

Una vez que la cabeza está en la pista correcta la latencia rotacional es el tiempo que tarda este en encontrar el sector en donde quiere leer o escribir.

Tiempo de transferencia:

Es el volumen de datos por unidad de tiempo, es decir, es el tiempo que se tarda en recuperar la información del disco o guardarla.

Tiempo medio entre fallos:

Básicamente es el tiempo medio de vida del disco, se refería cuando este ya no puede recuperarse de los fallos que van apareciendo durante su vida útil.

A mi criterio seria la latencia rotacional, que dependiendo de donde esta el dato en el disco este puede llegar a tardar más o menos. Por ej puede llegar a completar una vuelta para encontrar la información o como puede encontrarla al instante.

Explique los niveles de RAID 0, 1 y 5. A su criterio, ¿cuál es la principal razón para la implementación de unidades de almacenamiento redundante?

Raid 0:

Distribuye los datos equitativamente entre dos o más discos, estos suelen ser de igual capacidad. Una característica del raid cero es redundante. Proporciona un alto rendimiento de escritura ya que los datos se escriben en dos o más discos de forma paralela. Si un dato de un disco se pierde, se pierde toda la información y la fiabilidad es aproximadamente inversamente proporcional al número de discos del conjunto.

Raid 1:

Solo puede ser tan grande como el más pequeño de sus discos, es util cuando queremos tener más seguridad desaprovechando capacidad. Incrementa exponencialmente la fiabilidad respecto a un solo disco y la velocidad de lectura tan rápida como el número de discos que tengamos. Una de las principales desventajas es que pierde la mitad del almacenamiento y no mejora en rendimiento de escritura.

Raid 5:

Su principal característica es que distribuye la información de paridad, al tener múltiples discos la velocidad de lectura se multiplica por el número de discos menos uno, al tener múltiples discos si falla un disco no pasa nada. Se mejora la lectura por que se reparte entre todos los discos. La principal desventaja es que si fallan dos discos o más si que se pierde información.

La principal razón de usar raid es obviamente mantener los datos seguros en caso de fallas de disco, alargando el tiempo de probabilidad de que los discos fallen al mismo tiempo(el que guarda los datos y su respaldo). Teniendo así un respaldo seguro y completo de la información guardada.

Explique el porqué la organización basada en Árboles B y B+ resulta apropiada como estructura de datos para implementar índices ordenados

La estructura de los árboles B y B+ y su funcionamiento, es decir, la forma en que se añaden y eliminan los datos es conveniente para los índices ordenados, pues al hacer estas operaciones (insert y delete) el árbol se queda ordenado, esto ayuda a determinar si el dato también existe o no y retornarlo en caso de éxito en un tiempo casi lineal. Además esta estructura optimiza la búsqueda, porque los datos siempre están en la rama en donde se empieza a buscar y no en las otras.

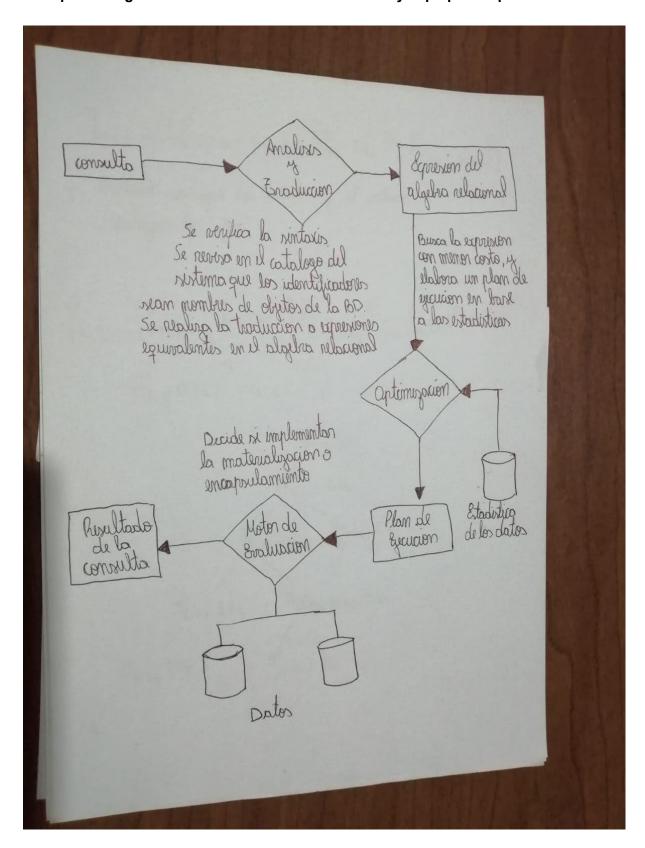
Indique para qué tipo de consultas resulta más apropiado:

- (a) un índice ordenado.
- (b) un índice hash.
- (c) un índice bitmap.

Una consulta del tipo (múltiples claves) es apropiado para un índice bitmap Una consulta del tipo (igualdad e igualdad múltiple) es apropiado para un índice hash Una consulta del tipo (desigualdad) es apropiado para un índice ordenado

Explique el costo asintótico espacial y temporal del Algoritmo de Programación Dinámica: (a) sin la optimización de evaluación de árboles en profundidad por la izquierda. (b) con la optimización de evaluación de árboles en profundidad por la izquierda

Grafique el Diagrama de Procesamiento de consultas y explique los pasos del mismo.



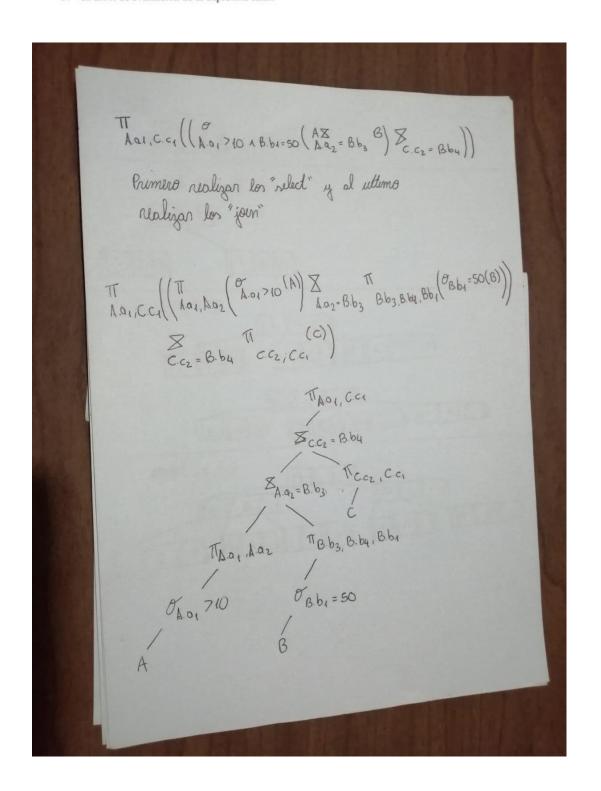
Resuelva el siguiente ejercicio y levante su desarrollo.

Dadas las relaciones A(a1, a2, ..., a20), B(b1, b2, ..., b12) y C(c1, c2, ..., c15), y la siguiente consulta:

select distinct A.a1, C.c1 from A join B on (A.a2 = B.b3) join C on (C.c2 = B.b4) where A.a1 > 10 and B.b1 = 50,

Muestre:

- 1. Su traducción directa al algebra relacional.
- 2. Los pasos para llegar a la expresión equivalente que minimice la cantidad de datos procesado por cada operación.
- 3. El árbol de evaluación de la expresión final.



Dada una operación de selección cualquiera basada en una condición de igualdad, explique en qué casos un SGBD utilizará los siguientes algoritmos e indique cuál es el costo asintótico de los mismos:

- (a) Búsqueda Lineal.
- (b) Búsqueda Binaria.
- (c) Búsqueda en índice primario para un atributo clave.
- (d) Búsqueda en índice secundario para atributo no clave.

Búsqueda lineal:

Es cuando necesariamente se revisan todos los bloques para ver si cumplen o no con la condición de selección, así como su nombre lo indica, es lineal la búsqueda. La razón de esto es que no se tiene un índice de clave de búsqueda, ni tampoco se tiene ordenado la tabla. Este algoritmo tiene un **costo = Br**.

Búsqueda binaria:

Esta clase de búsqueda se usa cuando NO se tiene un índice de clave, pero la tabla está ordenada según la clave de búsqueda. Es similar a tener un array ordenado y simplemente aplicar la función Búsqueda binaria, que en el peor de los casos lo encuentra en log2(Br). Cada uno de estos accesos a bloque requiere una búsqueda además de una transferencia de bloque, y por tanto el **coste = log2(Br) + (CS (A , r) / fr) - 1**.

Búsqueda en índice primario:

Como el índice está construido sobre el atributo clave, la búsqueda puede utilizar este índice para rescatar los datos. Por lo tanto para recuperar el único registro que cumple con la condición se necesita leer sólo un bloque. El **coste = AAi + 1**.

Búsqueda de índice secundario:

Cuando no se tiene ningún índice de clave de búsqueda ni tampoco algún atributo clave. En el mejor de los casos el campo indexado es una clave candidata, entonces de la exploración del índice resulta un puntero al registro deseado. Si el campo indexado no es una clave, de la exploración del índice se debe acceder a un cajón con CS(A,r) punteros, como el índice es secundario se estudia el peor caso, en el cual cada uno de los registros se encuentra en un bloque diferente, por lo tanto el coste=AAi+1+CS(A,r).

Indique los resultados del siguiente ejercicio.

Dadas las relaciones r1(A, B, C) y r2(C, D, E) con las siguientes propiedades: r1 tiene 40.000 tuplas, r2 tiene 90.000 tuplas, 100 tuplas de r1 caben en un bloque y 45 tuplas de r2 que caben en un bloque. Estimese el número de accesos a bloques requeridos utilizando las siguientes estrategias para la reunión "r1 join r2 on (r1.C = r2.C)":

- a- Reunión en bucle anidado.
- b- Reunión en bucle anidado por bloques.
- c- Reunión por mezcla, suponiendo además que la relación r1 debe ser ordenada externamente disponiéndose de 3 bloques de memoria intermedia.
- d- Reunión en bucle anidado indexada, suponiendo que existe un índice primario de árbol B+ en la columna C de la relación r2 con nodos de 60 punteros.

c.
$$400 + 2.000 + 400 * (2 * | log2 (400 / 3) | + 1) = 9.200$$

d.
$$400 + 40.000 * (| log30 (90.000) | + 1) = 200.400$$

Resuelva el siguiente ejercicio a mano alzada y levante una imagen de su desarrollo:

A – Determine si las siguientes planificaciones son o no secuenciables en cuanto a conflictos, e indique cual es el orden de las transacciones en caso afirmativo.

P1		
T1 T2		
Leer(A)		
	Escribir (A)	
Escribir(A)		
	Escribir(A)	

	P2
T1	T2
Leer(A)	
	Escribir (B)
	Escribir (A)
Leer(B)	

	P3	0-
T1	T2	Т3
Escribir(A)	Escribir(B)	
	Leer(C)	Escribir (C)

B – Determine si las siguientes planificaciones son o no secuenciables en cuanto a vistas, e indique cual es el orden de las transacciones en caso afirmativo.

	P1
T1	T2
Leer(A)	
	Escribir (A)
Escribir(A)	
	Escribir(A)

P2		
T1	T2	
Leer(A)		
	Escribir (B)	
	Escribir (A)	
Leer(B)	Estribil (r)	

	P3	
T1	T2	T3
Leer(A)		
	Leer(B)	
		Escribir(B)
Escribir(A)		
	Escribir(B)	
	3000 0000 00000	Leer(A)
		Escribir(B)

A)

P1 NO

P2 NO

P3 SI, el orden es T1-T3-T2

B) SI, el orden es T1-T2 NO SI, el orden es T1-T2-T3

Explique los tipos de índices estudiados conforme su organización física y cuando conviene aplicarlos.

Índice Ordenado:

Los registros índices están ordenados de acuerdo al valor de la clave de búsqueda. Pueden ser primarios o secundarios y conviene utilizarlos cuando se tiene búsquedas en rangos .

Primario: Son aquellos cuya clave especifica el orden secuencial del archivo indexado, ordena físicamente la tabla

Secundario: Son aquellos índices cuya clave de búsqueda no determinan el orden secuencial del archivo ordenado, no ordena físicamente la tabla

Índice asociativos o hash:

Los registros índices están almacenados en bloques de acuerdo a una función hash, útiles en condiciones de igualdad.

Indice Bitmap:

Los índices bitmaps son un tipo especial de índices diseñados para consultar eficientemente en múltiples claves y son útiles tanto para consultas de sobre un atributo o sobre varios atributos, siempre y cuando exista un índice bitmap en cada atributo.

Detalle los pasos lógicos para el Procesamiento de Consultas. Explique cada paso.

Analisis y Traduccion:

Verifica la sintaxis. Se revisa en el catálogo del sistema que todos los identificadores sean nombres de objetos de la base de datos. Se realiza la traducción a expresiones equivalentes en el álgebra relacional. El resultado es el conjunto o serie de expresiones del álgebra relacional a evaluar para obtener el resultado de la consulta.

Optimización:

Busca la expresión con menor costo, y con eso elabora un plan de ejecución en base a las estadísticas. Devuelve como resultado el plan de ejecución de la consulta.

Evaluación:

Decide si implementar la materialización o encapsulamiento.:

Materialización:

En la cual se evalúa una operación a la vez. empezando por las expresiones de nivel más bajo del árbol de operadores, el resultado se materializa en un archivo temporal, coste = coste operaciones + escritura de tablas temporales. Se usa el double buffering, para solapar cómputo y escritura.

Encausamiento:

Se evalúan varias operaciones simultáneamente. Los resultados de una operación se pasan a la siguiente utilizando una memoria intermedia, sin utilizar archivos temporales. Las entradas y salidas de las operaciones no están disponibles todas a la vez.

DESDE ACA ES OTRO PRIMER PARCIAL

Explique resumidamente y en sus propios términos el funcionamiento de los niveles de RAID 1 y 5.

Raid 1:

Funciona creando una copia exacta de un conjunto de datos en dos o más discos. Teniendo un respaldo idéntico de los datos en otro disco. Entonces por cada disco que se tiene se necesitaría una nuevo para poder implementar este nivel de raid Es útil cuando queremos tener más seguridad desaprovechando capacidad. Incrementa exponencialmente la fiabilidad respecto a un solo disco y la velocidad de lectura tan rápida como el número de discos que tengamos.

Raid 5:

Su principal característica es que distribuye la información de paridad, al tener múltiples discos la velocidad de lectura se multiplica por el número de discos menos uno, al tener múltiples discos si falla un disco no pasa nada. Se mejora la lectura por que se reparte entre todos los discos. La principal desventaja es que si fallan dos discos o más si que se pierde información.

Explique resumidamente y en sus propios términos a que corresponde un índice, a que un archivo índice y a que un registro índice.

Los índices son aquellos que te ahorran tiempo en hacer una búsqueda en una colección basta de registros, por ej un índice de un libro nos puede guiar más rápidamente al cap que estamos buscando.

Los índices son estructuras de una base de datos utilizados para acelerar el acceso a los datos deseados.

Mientras que los registro de índice consisten en un valor de la clave de búsqueda y punteros a uno o más registros con ese valor de la clave de búsqueda. La característica que tiene el puntero es que apunta a un bloque de disco, y tiene un desplazamiento dentro de este para encontrar el registro que se está buscando.

Teniendo en cuenta la consulta "select * from cuenta where saldo > 2500" y los siguientes datos estadísticos Br=100, Nr=2000, Fr=20, V(saldo, r)=20. Estímese en forma explicada el costo medio y máximo en lectura de bloques de la consulta indicada. Debe asumirse que en la tabla existen valores de saldo menores, mayores e iguales a 2500.

Suponiendo que 2500 fuera el valor medio de los valores de la columna saldo significa que hay 10 valores mayores a 2500. En promedio hay 100 filas con saldo mayor a 250, teniendo en cuenta que hay 100 filas en promedio por cada valor del saldo. En promedio hay 50 bloques con filas cuyo saldo es mayor a 2500, ya que en promedio hay 20 filas por bloque. Con el índice se puede planificar para que solo se realizan lecturas de estos 50 bloques. La selección entonces toma como coste promedio la lectura de 50 bloques. Realizar la proyección toma un tiempo de CPU igual a leer 1 bloque. El coste es igual a 51 bloques en promedio. El coste máximo es 101 bloques.

Explique resumidamente y en sus propios términos las posibles formas organización de los registros en archivos para la implementación de archivos de tablas/datos.

Montículo(heap): Son los que se colocan en cualquier registro en cualquier parte del archivo en el que haya espacio, por esta razón estos no están ordenados. Para consultas aleatorias.

Secuencial: Son los que se guardan en orden secuencial según su valor de la clave de búsqueda de cada uno de ellos. Para consultas de tipo tipo de rango.

Hash: Es el cual se tiene por algún atributo del registro una función asociativa para la cual está indicará en qué bloque se encuentra el archivo, sirve también para colocar a los archivos que se van ingresando. Para consultas de tipo unitarias (una sola fila).

En agrupación: Tiene la particularidad que en él se guardan los datos de diferentes relaciones, también los registros relacionados se guardan en el mismo bloque. Para consultas de tipo join.

Explique resumidamente, en orden y en sus términos, los pasos que se realizan para el procesamiento de consultas por parte de un SGBD.

Analisis y Traduccion:

Verifica la sintaxis. Se revisa en el catálogo del sistema que todos los identificadores sean nombres de objetos de la base de datos. Luego se realiza la traducción a expresiones equivalentes en el álgebra relacional. El resultado es el conjunto o serie de expresiones del álgebra relacional a evaluar para obtener el resultado de la consulta.

Optimización:

Busca la expresión con menor costo, y con eso elabora un plan de ejecución en base a las estadísticas. Devuelve como resultado el plan de ejecución de la consulta.

Evaluación:

Decide si implementar la materialización o Encausamiento.:

Materialización:

En la cual se evalúa una operación a la vez. empezando por las expresiones de nivel más bajo del árbol de operadores, el resultado se materializa en un archivo temporal. Se usa el double buffering, para solapar cómputo y escritura.

Encausamiento:

Se evalúan varias operaciones simultáneamente. Los resultados de una operación se pasan a la siguiente utilizando una memoria intermedia, sin utilizar archivos temporales. Las entradas y salidas de las operaciones no están disponibles todas a la vez.

Explique resumidamente y en sus términos, cuando debería optarse por el uso de índices bitmaps.

Los índices bitmaps son un tipo de índices apropiados en escenarios en donde la carga de trabajo esté basada consultas sobre atributos de valores discretos o discretizables y asimismo, en escenarios en donde se espera que la misma carga de trabajo requiera de consultar eficientemente en múltiples claves basados en esos atributos

Explique resumidamente y en sus términos, la organización de un bloque de datos para registros de longitud variable.

Son utilizados en BD para cuando se requiere guardar múltiples tipos de registros en una misma tabla, estos registros pueden tener una longitud variable o campos repetidos. Por lo que se puede decir que se adaptan al tamaño de la información incluida en ellos, en estos se utilizan delimitadores tanto para el fin campo como para el fin de registro. Estos pueden ser implementados como archivos de registros de longitud fija mediante los siguientes esquemas, Espacio reservado, Representación con listas, Estructura de bloques anclas y de desbordamiento.

Enumere y explique resumidamente y en sus términos, las medidas de rendimiento que deben tener en cuenta para la elección de unidades de discos magnéticos. ¿A su criterio, cuál de las mismas sería la más determinante?

Tiempo de acceso:

Tiempo que llega a leer o escribir datos desde su petición hasta su confirmación.

Tiempo de búsqueda:

Tiempo que tarda en ubicar el peine en la pista correcta. Al tener un disco más grande este puede tardar más tiempo en encontrar la pista a la cual está el dato que busca (los discos más pequeños tienen la ventaja que pueden tardar menos tiempo).

Latencia rotacional:

Una vez que la cabeza está en la pista correcta la latencia rotacional es el tiempo que tarda este en encontrar el sector en donde quiere leer o escribir.

Tiempo de transferencia:

Es el volumen de datos por unidad de tiempo, es decir, es el tiempo que se tarda en recuperar la información del disco o guardarla.

Tiempo medio entre fallos:

Básicamente es el tiempo medio de vida del disco, se refería cuando este ya no puede recuperarse de los fallos que van apareciendo durante su vida útil.

A mi criterio seria la latencia rotacional, que dependiendo de donde esta el dato en el disco este puede llegar a tardar más o menos. Por ej puede llegar a completar una vuelta para encontrar la información o como puede encontrarla al instante.

Dada una operación de selección cualquiera basada en una única condición de igualdad, explique en qué casos un SGBD utilizará los siguientes algoritmos y cual es el costo asintótico de los mismos: (a) Búsqueda Lineal. (b) Búsqueda Binaria. (c) Búsqueda en índice primario. (d) Búsqueda en índice secundario.

Búsqueda lineal:

Es cuando necesariamente se revisan todos los bloques para ver si cumplen o no con la condición de selección , así como su nombre lo indica, es lineal la búsqueda. La razón de esto es que no se tiene un índice de clave de búsqueda, ni tampoco se tiene ordenado la tabla. Este algoritmo tiene un costo = Br.

Búsqueda binaria:

Esta clase de búsqueda se usa cuando NO se tiene un índice de clave, pero la tabla está ordenada según la clave de búsqueda. Es similar a tener un array ordenado y simplemente aplicar la función Búsqueda binaria, que en el peor de los casos lo encuentra en log2(Br). Cada uno de estos accesos a bloque requiere una búsqueda además de una transferencia de bloque, y por tanto el coste = log2(Br) + (CS (A, r) / fr) - 1.

Búsqueda en índice primario:

Como el índice está construido sobre el atributo clave, la búsqueda puede utilizar este índice para rescatar los datos. Por lo tanto para recuperar el único registro que cumple con la condición se necesita leer sólo un bloque. El coste = AAi + 1.

Búsqueda de índice secundario:

Cuando no se tiene ningún índice de clave de búsqueda ni tampoco algún atributo clave. En el mejor de los casos el campo indexado es una clave candidata, entonces de la exploración del índice resulta un puntero al registro deseado. Si el campo indexado no es una clave, de la exploración del índice se debe acceder a un cajón con CS(A,r) punteros, como el índice

es secundario se estudia el peor caso, en el cual cada uno de los registros se encuentra en un bloque diferente, por lo tanto el coste= AAi + 1 + CS(A , r).

Indique los resultados del siguiente ejercicio.

Dadas las relaciones r1(A, B, C) y r2(C, D, E) con las siguientes propiedades: r1 tiene 40.000 tuplas, r2 tiene 90.000 tuplas, 100 tuplas de r1 caben en un bloque y 45 tuplas de r2 que caben en un bloque. Estímese el número de accesos a bloques requeridos utilizando las siguientes estrategias para la reunión "r1 join r2 on (r1.C = r2.C)":

- a- Reunión en bucle anidado.
- b- Reunión en bucle anidado por bloques.
- c- Reunión por mezela, suponiendo además que la relación r1 debe ser ordenada externamente disponiéndose de 3 bloques de memoria intermedia.
- d- Reunión en bucle anidado indexada, suponiendo que existe un índice primario de árbol B+ en la columna C de la relación r2 con nodos de 60 punteros.

```
nr1 = 40.000 fr1 = 100 br1 = 400

nr2 = 90.000 fr2 = 45 br2 = 2000

a. 400 + 40.000 * 2.000 = 80.000.400

b. 400 + 400 * 2000 = 800.400

c. 400 + 2.000 + 400 * (2 * | log2 (400 / 3) | + 1) = 9.200

d. 400 + 40.000 * (| log30 (90.000) | + 1) = 200.400
```

RECOPILACIÓN SEGUNDO PARCIAL

(a) Defina el concepto de Transacción en SGBDs. (b) Indique y defina las fases del Ciclo de Vida de una Transacción. (b) Indique y defina las propiedades que un SGBD debe asegurar para las Transacciones.

A)

Una transacción es un conjunto de operaciones, que acceden y posiblemente actualizan los datos, y que son tratados como una unidad.

B)

Activa

Es el estado al que pasa luego de comenzar su ejecución, y no cambia de estado durante las operaciones de lectura y escritura de ítems.

Parcialmente confirmada

Pasa a este estado cuando acaba (END). En este punto se realizan controles de concurrencia, y en el caso de fallo, los cambios no se graban de forma permanente. Pasa al siguiente estado cuando al hacer commit.

Confirmada

Punto de confirmación y conclusión de la ejecución.

Fallida

Si uno de los chequeos falla o si es abortada durante su estado activo.

Abortada

Se deshacen los efectos de sus operaciones de escritura sobre la BD.

Terminada

Pasa a este estado cuando la transacción desaparece del sistema.

C)

Atomicidad

Una transacción es una unidad atómica de procesamiento; es realizada enteramente o no es realizada en nada.

Consistencia

La ejecución de la transacción debe pasar la BD desde un estado consistente a otro también consistente.

Aislamiento

Una transacción no deberá hacer visible sus modificaciones a otras transacciones hasta que esté confirmada.

Persistencia

Cuando una transacción cambia la BD y los cambios son confirmados, estos cambios no deben perderse por fallos posteriores.

(a) Describa la función del Componente de Gestión de Concurrencia en un SGDB. (b) Describa la estructura de datos utilizada para la gestión y concesión de bloqueos.

A)

Se encarga de asegurar que el efecto de la ejecución concurrente de un conjunto de transacciones que se intercalan en el tiempo sea igual a que las transacciones se hubiesen ejecutado secuencialmente

B)

Para la gestión de bloqueos se utiliza una tabla de bloqueos que almacena los bloqueos concedidos y las peticiones solicitadas. Esta tabla es una tabla hash en memoria, cuyas entradas corresponden a los elementos de datos bloqueados, y por cada uno elemento de datos hay una lista enlazada con los registros de las solicitudes concedidas pero no liberadas y solicitudes pendientes

(a) Describa el protocolo de Bloqueo de 2 Fases. (b) Indique cuales son las variantes del mismo.

A)

El protocolo exige que cada transacción realice sus peticiones de bloqueo y desbloqueo en dos fases que son "Fase de crecimiento" y "Fase de decrecimiento". Inicialmente una transacción está en fase de crecimiento, una vez que libere un bloqueo entra en fase de decrecimiento

Fase de crecimiento (subir)

En esta fase se obtiene un bloqueo exclusivo, puede obtener bloqueos pero no liberarlos.

Fase de decrecimiento (bajar)

En esta fase se liberan los bloqueos compartidos, puede liberar bloqueos pero no obtener ninguno nuevo.

B)

Estricto

Libera los bloques exclusivos al finalizar la transacción. Tambien evitan los retrocesos en cascada

Riguroso

Libera todos los bloques al final de la transacción y las transacciones se pueden secuenciar en el orden que comprometen

- (a) Explique que es una Planificación Secuencial. (b) Explique que es una Planificación Secuenciable. (c) Fundamente a su criterio la importancia de la Secuencialidad en SGBD.
- A)

Consiste en una secuencia de instrucciones de varias transacciones, en la cual las instrucciones pertenecientes a una única transacción están juntas en dicha planificación. De este modo, para un conjunto de n transacciones existen n! planificaciones secuenciales válidas distintas.

- B)
 Si una planificación P puede convertirse en una planificación secuencial P', se dice que P es secuenciable.
- C)
 Esta permite que no ocurran cuellos de botella, actualizaciones perdidas, lectura sucia entre otros que son un fastidioso y costoso a la hora de ponernos a solucionar. Siempre queremos que nuestro SGDB cumpla con los principios de atomicidad, consistencia, aislamiento y persistencia para con los datos. Es gracias a la secuencialidad podemos estar seguros que los cumple, pues va a gestionar ordenadamente las transacciones concurrentes evitarnos los problemas mencionados anteriormente.

(a) Detalle los pasos de cada fase del protocolo C2F en Bases de Datos Distribuidas. (b) Indique como proceden los participantes en caso de falla del coordinador. (c) Indique como se procede un sitio en caso de falla del mismo.

A)

Fase 1

Ci añade el registro <preparar T> y la fuerza a guardar en un almacenamiento estable.

Ci envía este mensaje a todos los sitios en los que se ha ejecutado T.

Al recibir los mensajes de Ci, el gestor de transacciones de cada sitio determina si desea comprometer su parte de T.

Cuando el gestor da una respuesta negativa se añade el registro <no T> al registro histórico,

y responde enviando a Ci el mensaje abortar T.

Cuando el gestor da una respuesta positiva se añade el registro <T preparada> al registro histórico, y se guarda en un almacenamiento estable. Por último el gestor responde a Ci con el mensaje T preparada.

Fase 2

Ci recibe de todos los sitios las respuestas al mensaje preparar T, o cuando ha transcurrido un intervalo de tiempo especificado con anterioridad desde que se envió el mensaje preparar T.

Ci puede determinar si la transacción T puede comprometerse o abortarse

Si Ci ha recibido el mensaje T preparada de todos los sitios participantes, entonces la transacción T se puede comprometer.

Si Ci ha recibido el mensaje no T, hay que abortar la transacción T

El resultado <T comprometida> o <T abortada> se añade al registro histórico, que se guarda en un almacenamiento estable

B)

Si este falla durante la ejecución del protocolo de compromiso para la transacción T, los sitios participantes deben decidir el destino de T. Que se elige de la siguiente manera: Si algún sitio activo contiene <T comprometida> en su registro histórico, se debe comprometer T.

Si algún sitio activo contiene <T aborta> en su registro histórico, se debe abortar T.

Si no se da ninguno de los casos anteriores, todos los sitios activos deben tener el registro <T preparada>

C)

Si Ci detecta que un sitio ha fallado lo maneja de la siguiente manera:

Si el sitio falla antes de responder a Ci, el coordinador asume que ha respondido con abortar T.

Si el sitio falla después de responder a Ci, el coordinador ignora el fallo y ejecuta el resto del protocolo de manera normal.

Si el registro histórico contiene <T comprometida>, el sitio ejecuta rehacer(T).

Si el registro histórico contiene <T abortada>, el sitio ejecuta deshacer(T).

Si el registro histórico contiene <T preparada>, el sitio debe consultar con Ci para

determinar el destino de T.

Si Ci responde <T compromedida>, se hace rehacer(T)

Si Ci responde <T aborto>, se hace deshacer(T).

En cambio si Sk no contiene nada significa que el fallo ocurrió antes de la transmisión, eso signoficaria or lo tanto que T ya aborto y se realizo deshacer(T)

Explique detalladamente las formas de almacenamiento distribuido en Bases de Datos Distribuidas Relacionales.

Réplica de datos

Es cuando el sistema conserva varias copias idénticas de una misma relación, si esta relación se replica el sistema la guarda en dos o más sitios diferentes. En el caso de que se tenga una réplica completa esta se guardará en cada sitio del sistema Unas de las características principales son

Disponibilidad

Es el caso en que si algunos de los sitios en donde esta guardado la relación r falla, esta se pueda encontrar en otro sitio distinto. Asegurando así que el sistema pueda seguir con normalidad con las consultas que impliquen a r.

Paralelismo

Se pueden realizar consultas de lectura de diferentes sitios en donde se guardó la relación r, es decir de forma paralela. De esta manera cuantas más réplicas de r existan, mayor será la posibilidad de que los datos necesarios estén en el mismo sitio que en donde se ejecuta la transacción

Sobrecarga

Ya que el sistema guarda en diferentes sitios de una misma relación r, está a su vez tienen que tener la misma información, para evitar cálculos erróneos. Por tanto, siempre que se actualiza r, hay que propagar la actualización a todos los sitios que contienen réplicas, manteniendo así el sistema consistente.

Fragmentación de los datos

Es cuando en la base de datos fragmenta una relación r, este se divide en varios fragmentos

r2,...rn. Estos fragmentos contienen la suficiente información para permitir la reconstrucción original r. Se pueden hacer de dos maneras: la fragmentación horizontal o la vertical. La primera divide la relación asignando cada tupla de r a uno a más fragmentos.

Mientras que la segunda la descompone en el esquema r de la relación r

Y una de las características que posee son:

Horizontal

Conservan las tuplas en los sitios en que más se utilizan, minimizando así la transferencia de datos.

Permite realizar paralelismo de los fragmentos.

Vertical

Permite volcar los fragmentos donde sea más conveniente para la información.

Permite el paralelismo sobre una relación.

En ambos casos los fragmentos se pueden volver a fragmentar en cualquier version Conforme la figura de abajo y la consulta "select * from R join S". Indique los pasos y el costo total de trasmisión de realizar la Estrategia de la Semireunión si la consulta fue recibida: (a) en el Sitio 1, (b) en el Sitio 2.

Sitio	1 – R
A1	A2
1	3
1	4
1	6
2	3
2 2 3	6
3	7
3	8
3	9

A)

2 3 13 16 2 3 14 16 3 7 13 17]

	Sitio 2 –	S
A2	A3	A4
3	13	16
3	14	16
7	13	17
10	14	16
10	15	17
11	15	16
11	15	16
12	15	16

```
R join S on (R.A2 = S.A2)
Paso 1
Temp 1 = pi(R intersection S)
Temp_1 = [3, 4, 6, 7, 8, 9]
Costo = 6ui
Paso 2
Enviar Temp_1 a S2
Paso 3
Temp_2 = S1 (A2) Temp_1
Temp 2 = [3 \ 13 \ 16]
3 14 16
7 13 17]
Costo = 9ui
Paso 4
Enviar Temp_2 a S1
Paso 5
R = S1 (A2) Temp_2
R = [1 3 13 16
1 3 14 16
```

Costo 1 = 6 + 9Costo 1 = 15 ui

Costo 2 = 24 ui

Conclusión

Por lo tanto se ahorra mas en el envio de las unidades de transferencia por medio de la semi union

B)

- (a) Detalle el protocolo de Control de Concurrencia de Quorum de Consenso. (b) Explique las implicancias de la condición que debe tenerse en cuenta para la definición de los valores de Quorum. (c) Indique los valores de Quorum que permiten emular el Protocolo de Mayoría y el Protocolo Sesgado.
- A)

Es una generalización de los protocolos de Mayoría y Sesgado, donde cada sitio tiene asignado un peso, siendo S es la suma de todos los pesos de los sitios.

Para cada dato q se escogen dos valores que son Qr y Qw, que es el quórum de lectura y escritura respectivamente. Para cada Qr y Qw se tiene que cumpliar la siguiente condicion Qr + Qw > S y 2*Qw > S.

B)

Si un sitio necesita realizar una lectura debe bloquear tantas replicas tal que la suma de sus pesos sea mayor o igual a Qr. Si un sitio necesita realizar una escritura debe bloquear tantas réplicas tal que la suma de sus pesos sea mayor o igual a Qw.

Que se cumpla la condición implica que los bloqueos compartidos y exclusivos son incompatibles, esto quiere decir que cuando haya un bloqueo de lectura no se puede realizar

un bloqueo de escritura, y esto funciona también al revés

C)

La forma en que ambos protocolos se puedan emular es cuando se asume que todos los pesos son iguales, y se hace que Qr = Qw = (n/2) + 1, para asegurar que más de la mitad de las réplicas esten bloqueadas.

En cambio para emular el protocolo de Sesgado se hace Qr = 1y Qw = n, ya que para la lectura se necesita solo un sitio, pero para la escritura se necesitan las n réplicas.

Resuelva el siguiente planteamiento

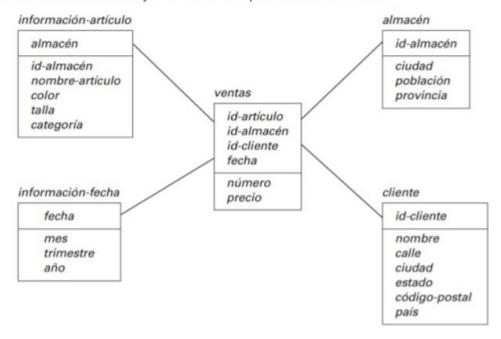
Una empresa te contrata como su nuevo Analista de Datos. Actualmente la empresa, tiene cierto grado de madurez y, cuenta con un Data Warehouse (DWH) sobre un PostgreSQL para el procesamiento analítico de sus datos.

Usted sabe que se cuenta con datos históricos de ventas de los últimos 10 años de operativa. El periodo de actualización del DWH es diario.

A continuación, el Departamento de Marketing te solicita la extracción de información del DWH para su campaña de promoción. Por lo tanto, se desea saber:

- Los clientes activos que no han realizado ninguna compra en los últimos 6 meses.
- Los 10 artículos más vendidos en los últimos 5 años, no se debe considerar las ventas del año en vigencia. Además, incluir el monto total de venta.

Dado el siguiente Esquema en Estrella. Escriba las sentencias SQL genéricas para la extracción de información y satisfacer los requerimientos de usuarios.



Explique en sus términos en qué consisten las tablas de dimensiones, tablas de hechos y medidas en el modelado multidimensional. Así mismo, enumere al menos tres ejemplos para cada uno.

Tabla de dimensiones

Son las que restringen los rangos de los datos y brinda detalles adicionales para los usuarios. Múltiples tablas de dimensiones se utilizan para definir los parámetros de los que dependen las tablas de hechos y medidas

Ej: Productos, Clientes, Proveedores

Tabla de hechos y medidas

Son los datos duros a ser analizados. Son la intersección de sus dimensiones definidas Ej: Ventas, Envios, Compras

Explique en sus términos: ¿Cuál es la diferencia entre bases de datos OLTP y OLAP?. Así mismo, cite al menos dos ejemplos de aplicación para cada tipo.

OLTP

Se utiliza mucho para aplicaciones back end, con frecuente acceso y frecuente escritura. Tiene una respuesta rápida y es fácil de usar y ofrece prioridad transaccional sobre el análisis de datos. Se basa en la estructura de datos pila. Se utiliza mucho en operaciones y transacciones de negocios de las empresas.

Ej:

Base de datos de un banco, porque se necesita hacer múltiples operaciones de manera muy rápida y eficiente.

Administración de datos de compra y venta de una empresa.

OLAP

Se necesitan grandes recursos computacionales para sacar el máximo provecho, además no se borran registros, solo se insertan o se modifican por lo que se maneja grande cantidades de datos. Se requiere tener muchos registros para poder trabajar en cuento a ello para que los pronósticos sean efectivos. A diferencia de OLTP tiene una curva de aprendizaje muy alta por las grandes cantidades de datos que maneja. Se basa en una estructura de columna, se consulta en conjunto, por lo que la información es más completa. Ej:

Análisis clínico. (Historial clínico) con los datos del paciente se le puede anticipar a enfermedades o ver que medicamento le resultará mejor de acuerdo a sus datos. Minería de datos

DESDE ACA ES OTRO SEGUNDO PARCIAL

Explique brevemente en sus términos: Tres objetivos principales del Data Warehousing y Business Intelligence. Así mismo, enumere al menos dos ejemplos de aplicación para los Sistemas de Apoyo en la Toma de Decisiones.



DATA WAREHOUSE (DW)

El objetivo principal de un DW es proporcionar las prestaciones necesarias para la transformación de la base de datos de una organización, generalmente transaccional, en línea y operativa denominada base de datos OLTP (On-Line Transaction Processing), a una base de datos más grande que contiene el histórico de todos los datos de interés existentes en la organización, denominada base de datos OLAP (On-Line Analytical Processing) y también conocida como propia DW.

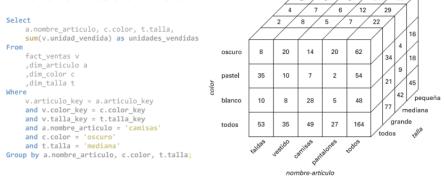
Ejemplos de SSDs:

- -Riskturn para presupuesto de capital basado en riesgo.
- -Pentaho para BI
- -SAP BusinessObjects para optimización empresarial
- -Eidos para razonamiento visual y representación del conocimiento para apoyar estrategias basadas en escenarios, resolución de problemas y mejor toma de decisiones.

Explique brevemente en sus términos: En el modelado dimensional, ¿cuál es la diferencia entre el esquema en estrella y los cubos OLAP?. Así mismo, cite al menos dos consideraciones de implementación de los cubos OLAP.

- Un CUBO permite que los datos sean modelados y visualizados en múltiples dimensiones.
- Un cubo está definido por 2 componentes:
- Tablas de Dimensiones.
- Tablas de Hechos.
- Dimension Tables: tales como ítems (nombre, tipo, marca), o tiempo (días, semanas, meses, años)
- Fact Table: Contiene las medidas (ej: ventas en pesos) y las claves para cada una de las tablas de dimensiones relacionadas.





para el esquema estrella

- Es el esquema más utilizado, donde el DW contiene:
 - Una gran tabla central (Fact Table) que contiene el volumen de datos sin redundancia.
 - Un conjunto de tablas relacionadas (Dimension Tables) una por cada dimensión.

- Cada dimensión es representada por una única tabla y cada tabla contiene un conjunto de atributos.
- Los atributos de una dimensión pueden formar una Jerarquía (Orden Total) o una grilla (lattice) (Orden Parcial).



• RECOPILACIÓN FINALES

Describa el protocolo de compromiso de 2 fases. Así mismo indique como se procede: (a) en caso de falla del coordinador y (b) en caso de falla de un sitio participante.

Este empieza su ejecución cuando se acaba de ejecutar una transaccion T, es ahí cuando inicia el protocolo C2F:

Fase 1

Ci prepara T y la fuerza a guardar.

Ci envia este mensaje a todos los sitios involucrados

Al recibir los mensajes de Ci, el gestor de transacciones de cada sitio determina si desea comprometer su parte de T.

Cuando el gestor da una respuesta negativa dice <no T>, y responde enviando a Ci el mensaje abortar T.

Cuando el gestor da una respuesta positiva dice <T preparada> al registro histórico, y se guarda, luego el gestor responde a Ci con el mensaje T preparada.

Fase 2

Cuando Ci recibe de todos los sitios las respuestas al mensaje preparar T, o cuando ha transcurrido un intervalo de tiempo, empieza a fase 2:

Ci puede determinar si la transacción T se compromete o aborta

Si Ci ha recibido el mensaje T preparada de todos los sitios participantes, entonces la transacción T se puede comprometer.

Si Ci ha recibido un mensaje no T, hay que abortar la transacción

El resultado <T comprometida> o <T abortada> se guarda.

a)

En caso de falla del coordinador

Si este falla durante la ejecución del protocolo de compromiso para la transacción T, los sitios participantes deben decidir el destino de T:

Si algún sitio activo contiene <T comprometida>, se debe comprometer T.

Si algún sitio activo contiene <T aborta>, se debe abortar T.

Si no se da ninguno de los casos anteriores, todos los sitios activos deben tener el registro <T preparada>

b)

En caso de falla de un sitio participante

Si Ci detecta que un sitio ha fallado:

Si falla antes de responder a Ci, el coordinador asume que ha respondido con abortar T.

Si falla después de responder a Ci, el coordinador ignora el fallo.

Describa el Algoritmo del Luchador. Explique acercar de su aplicabilidad en SGBDD. Desarrollo el concepto de Disponibilidad y explique como se relaciona con la Reconfiguración y la Recuperación.

El algoritmo luchador es un procedimiento que se activa en una red distribuida cuando el coordinador de una transaccion falla pasado un cierto intervalo de tiempo, al detectar esto el sitio trata de convertirse en el nuevo coordinador, envía un mensaje de elección a todos los sitios con mayor identificación y espera un tiempo determinado por una respuesta. Cuando no hay respuesta, Si asume que todos los sitios de mayor identificación han fallado y se elige a sí mismo como coordinador, pero cuando hay una respuesta, aguarda un nuevo tiempo determinado para recibir la respuesta del nuevo sitio con mayor identificación que ha sido elegido. Cuando no se recibe un mensaje del nuevo coordinador se reinicia el algoritmo.

Después de que el sitio original se recupera, comienza de inmediato la ejecución de este mismo algoritmo. Si no hay ningún sitio activo con un número más elevado que el sitio recuperado, este obliga a todos los sitios menores a permitirle transformarse en el nuevo sitio coordinador, aunque ya haya un coordinador activo con una jerarquia mas baja.

Disponibilidad

Los sd se implementan para conseguir alta disponibilidad, es decir que la falta de un sitio no provoque que se pierdan los datos y que no se puedan acceder ni modificar

Reconfiguración

Readaptar la configuración del sistema distribuido para continuar con el cómputo.

Debe basarse en

Abortar las transacciones que estaban activas en el sitio que ha fallado (se logra en parte con C2F)

Evitando que ésta interfiera con nuevas transacciones por mantenerse los bloqueos Sin embargo es posible que ciertas transacciones puedan continuar en otros sitios en donde exista réplica de los datos.

Si el sitio que falla posee réplicas de datos, el catálogo del sistema debe ser modificado para no enviar transacciones a ese sitio hasta que se recupere.

Si ha fallado un sitio que hospedaba un servidor central de algún subsistema debe elegirse un nuevo sitio que los remplace

Explique: (i) el protocolo de control de bloqueo distribuido de Quórum de Consenso, (ii) que implica el que se cumpla cada una de las condiciones del protocolo y (iii) la configuración de parámetros que deben aplicarse para emular los protocolos de Mayoría y Sesgado.

A)

Es una generalización de los protocolos de Mayoría y Sesgado, donde cada sitio tiene asignado un peso, siendo S es la suma de todos los pesos de los sitios.

Para cada dato q se escogen dos valores que son Qr y Qw, que es el quórum de lectura y escritura respectivamente. Para cada Qr y Qw se tiene que cumpliar la siguiente condicion

B)

Qr + Qw > Sy 2*Qw > S.

Si un sitio necesita realizar una lectura debe bloquear tantas replicas tal que la suma de sus pesos sea mayor o igual a Qr. Si un sitio necesita realizar una escritura debe bloquear tantas réplicas tal que la suma de sus pesos sea mayor o igual a Qw.

Que se cumpla la condición implica que los bloqueos compartidos y exclusivos son incompatibles, esto quiere decir que cuando haya un bloqueo de lectura no se puede realizar

un bloqueo de escritura, y esto funciona también al revés

C)

La forma en que ambos protocolos se puedan emular es cuando se asume que todos los pesos son iguales, y se hace que Qr = Qw = (n/2) + 1, para asegurar que más de la mitad de las réplicas esten bloqueadas.

En cambio para emular el protocolo de Sesgado se hace Qr = 1y Qw = n, ya que para la lectura se necesita solo un sitio, pero para la escritura se necesitan las n réplicas.

Explique el porqué la organización basada en Árboles B y B+ resulta apropiada como estructura de datos para implementar índices ordenados

La estructura de los árboles B y B+ y su funcionamiento, es decir, la forma en que se añaden y eliminan los datos es conveniente para los índices ordenados, pues al hacer estas operaciones (insert y delete) el árbol se queda ordenado, esto ayuda a determinar si el dato

también existe o no y retornarlo en caso de éxito en un tiempo casi lineal. Además esta estructura optimiza la búsqueda, porque los datos siempre están en la rama en donde se empieza a buscar y no en las otras.

Explique los tipos de índices estudiados conforme su organización física y cuando conviene aplicarlos.

Índice Ordenado:

Los registros índices están ordenados de acuerdo al valor de la clave de búsqueda. Pueden ser primarios o secundarios y conviene utilizarlos cuando se tiene búsquedas en rangos . Primario: Son aquellos cuya clave especifica el orden secuencial del archivo indexado, ordena físicamente la tabla

Secundario: Son aquellos índices cuya clave de búsqueda no determinan el orden secuencial del archivo ordenado, no ordena físicamente la tabla

Índice asociativos o hash:

Los registros índices están almacenados en bloques de acuerdo a una función hash, útiles en condiciones de igualdad.

Indice Bitmap:

Los índices bitmaps son un tipo especial de índices diseñados para consultar eficientemente en múltiples claves y son útiles tanto para consultas de sobre un atributo o sobre varios atributos, siempre y cuando exista un índice bitmap en cada atributo.

Detalle los pasos lógicos para el Procesamiento de Consultas. Explique cada paso.

Analisis y Traduccion:

Verifica la sintaxis. Se revisa en el catálogo del sistema que todos los identificadores sean nombres de objetos de la base de datos. Se realiza la traducción a expresiones equivalentes en el álgebra relacional. El resultado es el conjunto o serie de expresiones del álgebra relacional a evaluar para obtener el resultado de la consulta.

Optimización:

Busca la expresión con menor costo, y con eso elabora un plan de ejecución en base a las estadísticas. Devuelve como resultado el plan de ejecución de la consulta.

Evaluación:

Decide si implementar la materialización o encapsulamiento.:

Materialización:

En la cual se evalúa una operación a la vez. empezando por las expresiones de nivel más bajo del árbol de operadores, el resultado se materializa en un archivo temporal, coste = coste operaciones + escritura de tablas temporales. Se usa el double buffering, para solapar cómputo y escritura.

Encausamiento:

Se evalúan varias operaciones simultáneamente. Los resultados de una operación se pasan a la siguiente utilizando una memoria intermedia, sin utilizar archivos temporales. Las entradas y salidas de las operaciones no están disponibles todas a la vez.

Dada una operación de selección cualquiera basada en una condición de igualdad simple, indique que condiciones físicas obligarían a un SGBD utilizar cada uno de los siguientes algoritmos, indicando además el costo asintótico correspondiente en cada caso: (1) Búsqueda Lineal. (2) Búsqueda Binaria. (3) Búsqueda en índice primario. (4) Búsqueda en índice secundario.

Búsqueda lineal:

Es cuando necesariamente se revisan todos los bloques para ver si cumplen o no con la condición de selección , así como su nombre lo indica, es lineal la búsqueda. La razón de esto es que no se tiene un índice de clave de búsqueda, ni tampoco se tiene ordenado la tabla. Este algoritmo tiene un costo = Br.

Búsqueda binaria:

Esta clase de búsqueda se usa cuando NO se tiene un índice de clave, pero la tabla está ordenada según la clave de búsqueda. Es similar a tener un array ordenado y simplemente aplicar la función Búsqueda binaria, que en el peor de los casos lo encuentra en log2(Br). Cada uno de estos accesos a bloque requiere una búsqueda además de una transferencia de bloque, y por tanto el coste = log2(Br) + (CS (A, r) / fr) - 1.

Búsqueda en índice primario:

Como el índice está construido sobre el atributo clave, la búsqueda puede utilizar este índice para rescatar los datos. Por lo tanto para recuperar el único registro que cumple con la condición se necesita leer sólo un bloque. El coste = AAi + 1.

Búsqueda de índice secundario:

Cuando no se tiene ningún índice de clave de búsqueda ni tampoco algún atributo clave. En el mejor de los casos el campo indexado es una clave candidata, entonces de la exploración del índice resulta un puntero al registro deseado. Si el campo indexado no es una clave, de la exploración del índice se debe acceder a un cajón con CS(A,r) punteros, como el índice es secundario se estudia el peor caso, en el cual cada uno de los registros se encuentra en un bloque diferente, por lo tanto el coste= AAi + 1 + CS(A,r).

Explique en sus términos: ¿Por qué el modelado multidimensional es empleado para el análisis de datos en lugar del modelo relacional tradicional?

Los modelos de datos dimensionales son mejores donde se requiera grandes consultas de agregación, con poca escritura y mucha lectura. Mientras que los modelos relaciones son mejores donde se requiera manejar mucha escritura y poca lectura para mantener la integridad y consistencia de la información.

Explique en sus términos: ¿Cuál es la diferencia entre bases de datos OLTP y OLAP?. Así mismo, cite al menos dos ejemplos de aplicación para cada tipo.

OLTP

Se utiliza mucho para aplicaciones back end, con frecuente acceso y frecuente escritura. Tiene una respuesta rápida y es fácil de usar y ofrece prioridad transaccional sobre el análisis de datos. Se basa en la estructura de datos pila. Se utiliza mucho en operaciones y transacciones de negocios de las empresas.

Ej:

Base de datos de un banco, porque se necesita hacer múltiples operaciones de manera muy rápida y eficiente.

Administración de datos de compra y venta de una empresa.

OLAP

Se necesitan grandes recursos computacionales para sacar el máximo provecho, además no se borran registros, solo se insertan o se modifican por lo que se maneja grande cantidades de datos. Se requiere tener muchos registros para poder trabajar en cuento a ello para que los pronósticos sean efectivos. A diferencia de OLTP tiene una curva de aprendizaje muy alta por las grandes cantidades de datos que maneja. Se basa en una estructura de columna, se consulta en conjunto, por lo que la información es más completa. Ej:

Análisis clínico. (Historial clínico) con los datos del paciente se le puede anticipar a enfermedades o ver que medicamento le resultará mejor de acuerdo a sus datos. Minería de datos

(i) Explique en sus términos: ¿Por qué se dice que los datos son el nuevo activo de las empresas?. (ii) Así mismo, enumere al menos tres beneficios de utilizar un Data Warehouse. (iii) Explique en sus términos los pasos para realizar un ETL y enumere al menos tres casos de aplicación real.

i

los datos se han convertido en el activo más importante para las empresas, este es considerado por muchos el recurso más abundante en la actualidad, ya que digamos que cada persona tiene su huella digital, es decir su información personal en algún lugar de internet. Por ello, es que las empresas ven la importancia vital que tienen los datos para mantenerlas competitivas.

ii

Consolidación y homogeneización de la información. Mejor comunicación entre departamentos de la empresa. Entrega de información relevante que antes no se almacenaba

iii

Lo primero que se tiene que hacer es la extracción, para ello se sintetiza toda la información en una o varias estructuras comunes en las que se almacenen los datos normalizados, dejándolos completamente homogeneizados, organizados y listos para la fase de

transformación.

Luego viene la transformación, en donde aportamos valor a los datos obtenidos en la fase de extracción.

Y por último la carga, cuando el sistema recibe los datos debidamente procesados y los almacena en el destino que se haya definido. En esta etapa también se aísla a la fase de transformación de posibles cambios en el destino.

- -Ingestas y transformaciones de datos estructurados.
- -La fuente de datos y el destino usan tecnologías y tipos de datos distintos.
- -Los volúmenes de datos a transformar o procesar son manejables

Explique las formas de organización física de los archivos de datos en un SGBD.

Los archivos se pueden organizar de cuatro maneras

Montículo(heap): Son los que se colocan en cualquier registro en cualquier parte del archivo en el que haya espacio, por esta razón estos no están ordenados. Para consultas aleatorias.

Secuencial: Son los que se guardan en orden secuencial según su valor de la clave de búsqueda de cada uno de ellos. Para consultas de tipo tipo de rango.

Hash: Es el cual se tiene por algún atributo del registro una función asociativa para la cual está indicará en qué bloque se encuentra el archivo, sirve también para colocar a los archivos que se van ingresando. Para consultas de tipo unitarias (una sola fila).

En agrupación: Tiene la particularidad que en él se guardan los datos de diferentes relaciones, también los registros relacionados se guardan en el mismo bloque. Para consultas de tipo join.

El que siempre va a funcionar es el secuencial.

A – Determine si las siguientes planificaciones son o no secuenciables en cuanto a conflictos, e indique cual es el orden de las transacciones en caso afirmativo.

P1	
T1	T2
Leer(A)	
	Escribir (A)
Escribir(A)	
	Escribir(A)

P2		
T1	T2	
Leer(A)		
100	Escribir (B)	
	Escribir (A)	
Leer(B)		

	P3	0-	
T1	T2	T3	
Escribir(A)	Escribir(B)		
	Leer(C)	Escribir (C)	

B – Determine si las siguientes planificaciones son o no secuenciables en cuanto a vistas, e indique cual es el orden de las transacciones en caso afirmativo.

P1			
T1	T2		
Leer(A)			
	Escribir (A)		
Escribir(A)			
	Escribir(A)		

P2				
T1	T2			
Leer(A)				
	Escribir (B)			
	Escribir (A)			
Leer(B)				

	P3		
T1	T2	T3	
Leer(A) Escribir(A)	Leer(B)	Escribir(B)	
	Escribir(B)	Leer(A) Escribir(B)	

A)

P1 NO

P2 NO

P3 SI, el orden es T1-T3-T2

B)

SI, el orden es T1-T2

NO

SI, el orden es T1-T2-T3

```
A- Plan 1: No
Plan 2: No
Plan 3: Si
Plan 3: T1
                  T2
                             T3
     Escribir (A)
                Escribir(B)
                Leer (C)
                           Escribir(C)
B- Plan 1: Si
Plan 1: T1
      Leer(A)
      Escribir(A)
                 Escribir(A)
                 Escribir(A)
Plan 2: No
Plan 3: Si
Plan 3: T1
                   T2
                              T3
      Leer(A)
      Escribir(A)
                  Leer(B)
                  Escribir(B)
                           Escribir(B)
                           Leer(A)
                            Escribir(B)
```

Explique en forma precisa las formas de Almacenamiento Distribuido que pueden ser implementadas por SGBDD.

Réplica de datos

Es cuando el sistema conserva varias copias idénticas de una misma relación, si esta relación se replica el sistema la guarda en dos o más sitios diferentes. En el caso de que se tenga una réplica completa esta se guardará en cada sitio del sistema Unas de las características principales son

Disponibilidad

Es el caso en que si algunos de los sitios en donde esta guardado la relación r falla, esta se pueda encontrar en otro sitio distinto. Asegurando así que el sistema pueda seguir con normalidad con las consultas que impliquen a r.

Paralelismo

Se pueden realizar consultas de lectura de diferentes sitios en donde se guardó la relación r, es decir de forma paralela. De esta manera cuantas más réplicas de r existan, mayor será la posibilidad de que los datos necesarios estén en el mismo sitio que en donde se ejecuta la transacción.

Sobrecarga

Ya que el sistema guarda en diferentes sitios de una misma relación r, está a su vez tienen que tener la misma información, para evitar cálculos erróneos. Por tanto, siempre que se actualiza r, hay que propagar la actualización a todos los sitios que contienen réplicas, manteniendo así el sistema consistente.

Fragmentación de los datos

Es cuando en la base de datos fragmenta una relación r, este se divide en varios fragmentos

r2,...rn. Estos fragmentos contienen la suficiente información para permitir la reconstrucción original r. Se pueden hacer de dos maneras: la fragmentación horizontal o la vertical. La primera divide la relación asignando cada tupla de r a uno a más fragmentos. Mientras que la segunda la descompone en el esquema r de la relación r Y una de las características que posee son:

Horizontal

Conservan las tuplas en los sitios en que más se utilizan, minimizando así la transferencia de datos.

Permite realizar paralelismo de los fragmentos.

Vertical

Permite volcar los fragmentos donde sea más conveniente para la información.

Permite el paralelismo sobre una relación.

En ambos casos los fragmentos se pueden volver a fragmentar en cualquier versión.

Explique el algoritmo del Ascensor implementado en para el acceso a la información en Unidades de Discos Magnéticos. Indique además las principales métricas de rendimiento para la selección de unidades de almacenamiento.

El algoritmo del ascensor consiste en mover el cabezal de lectura en una dirección hasta atender todas las solicitudes en dicha dirección y luego repetir la operación en dirección inversa.

Las métricas son:

Tiempo de Acceso:

Tiempo que toma leer o escribir datos desde su petición hasta su confirmación.

Tiempo de búsqueda:

Tiempo que se tarda en ubicar el cabezal de lectura en la pista correcta. 4 a 10 ms.

Latencia Rotacional:

Tiempo que tarda en aparecer el sector a escribir/leer debajo de los cabezales. 4 a 15 ms.

Taza de Transferencia

Volumen de datos por unidad de tiempo que se pueden guardar o recuperar del disco.

Típicamente de 30 a 100 MB/s para lectura

20 a 85 MB/s para escritura.

Tiempo medio de fallo (TMDF):

El lapso de tiempo que un solo disco puede trabajar continuamente sin fallas. De 3 a 5 años.

(i) Indique la importancia del Catálogo del Sistema/Diccionario de Datos.

(ii) Detalle mínimamente la información almacenada en el mismo

- i) Guarda información acerca del sistema y sus datos (metadatos) y los guarda en la misma base de datos, se debe mantener en memoria para permitir un acceso rápido al mismo.
 ii)
- -Información acerca de la relaciones: Nombre de las relaciones, Nombre y tipo de los atributos de cada relación, Nombre y definiciones de las vistas y las restricciones de integridad.
- -Cuentas de usuario incluyendo nombre y contraseña
- -Información estadística y descriptiva: Número de tuplas de cada relación y Método de almacenamiento de cada relación.
- -Información de la organización física: Tipo de almacenamiento para cada relación y Localización física de cada relación
- -Información de los índices: Nombre del índice y de su relación, Tipo de índice y atributos sobre los cuales se crea el índice.

(i) Explique la importancia del Almacenamiento Redundante. (ii) Describa los Niveles de RAID 1 y 5.

i)

La principal razón de usar raid es obviamente mantener los datos seguros en caso de fallas de disco, alargando el tiempo de probabilidad de que los discos fallen al mismo tiempo(el que guarda los datos y su respaldo). Teniendo así un respaldo seguro y completo de la información guardada.

ii)

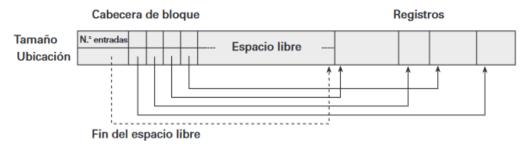
Raid 1:

Solo puede ser tan grande como el más pequeño de sus discos, es util cuando queremos tener más seguridad desaprovechando capacidad. Incrementa exponencialmente la fiabilidad respecto a un solo disco y la velocidad de lectura tan rápida como el número de discos que tengamos. Una de las principales desventajas es que pierde la mitad del almacenamiento y no mejora en rendimiento de escritura.

Raid 5:

Su principal característica es que distribuye la información de paridad, al tener múltiples discos la velocidad de lectura se multiplica por el número de discos menos uno, al tener múltiples discos si falla un disco no pasa nada. Se mejora la lectura por que se reparte entre todos los discos. La principal desventaja es que si fallan dos discos o más si que se pierde información.

Ilustre y sescriba la Estructura de Páginas con Ranura para la implementación de Registros de Datos de Longitud Variable.



Hay una cabecera al principio de cada bloque que contiene la información siguiente:

- 1. El número de elementos del registro de la cabecera
- 2. El final del espacio vacío del bloque
- 3. Un array cuyas entradas contienen la ubicación
- y el tamaño de cada registro

Los registros se ubican de manera contigua en el bloque, empezando desde el final del mismo. El espacio libre dentro del bloque es contiguo, entre la última entrada del array de la cabecera y el primer registro. Si se inserta un registro se le asigna espacio al final del espacio libre y se añade a la cabecera una entrada que contiene su tamaño y su ubicación.

Explique brevemente la ventaja de los Arreglos Redundantes de Discos (RAID) en cuanto a: 1-) Rendimiento. 2-) Fiabilidad. Detalle brevemente los niveles de RAID 0, 1 y 5.

La principal razón de usar raid es obviamente mantener los datos seguros en caso de fallas de disco, alargando el tiempo de probabilidad de que los discos fallen al mismo tiempo(el que guarda los datos y su respaldo). Teniendo así un respaldo seguro y completo de la información guardada.

En cuanto al rendimiento se puede decir que dependiendo el tipo de raid que se usa se puede mejorar el tiempo de lectura de datos o de escritura. Ya que la misma informacion se divide y se podra guardar en varios discos acortando estos tiempos.

Raid 0:

Distribuye los datos equitativamente entre dos o más discos, estos suelen ser de igual capacidad. Una característica del raid cero es redundante. Proporciona un alto rendimiento de escritura ya que los datos se escriben en dos o más discos de forma paralela. Si un dato de un disco se pierde, se pierde toda la información y la fiabilidad es aproximadamente inversamente proporcional al número de discos del conjunto.

Raid 1:

Solo puede ser tan grande como el más pequeño de sus discos, es util cuando queremos tener más seguridad desaprovechando capacidad. Incrementa exponencialmente la fiabilidad respecto a un solo disco y la velocidad de lectura tan rápida como el número de discos que tengamos. Una de las principales desventajas es que pierde la mitad del almacenamiento y no mejora en rendimiento de escritura.

Raid 5:

Su principal característica es que distribuye la información de paridad, al tener múltiples discos la velocidad de lectura se multiplica por el número de discos menos uno, al tener múltiples discos si falla un disco no pasa nada. Se mejora la lectura por que se reparte entre todos los discos. La principal desventaja es que si fallan dos discos o más si que se pierde información.

Explique la estructura de "páginas con ranuras" para la implementación de bloques de registros de longitud variable en un SGBD.

La estructura puede describirse de la siguiente manera Una cabecera al principio de cada bloque que contiene la información siguiente

- -El número de elementos del registro de la cabecera
- -El final del espacio vacío del bloque
- -Un array cuyas entradas contienen la ubicación y el tamaño de cada registro

Los registros se ubican de manera contigua en el bloque, empezando desde el final del mismo. El espacio libre dentro del bloque es contiguo, entre la última entrada del array de la cabecera y el primer registro. Si se inserta un registro se le asigna espacio al final del espacio libre y se añade a la cabecera una entrada que contiene su tamaño y su ubicación.

Conforme la siguiente tabla, suponiendo que los datos fueron insertados secuencialmente conforme se ilustra a continuación, grafique:

- a-) El índice de árbol b+ resultante, con nodos de 3 punteros, para la columna de clave primaria "email".
- b-) El índice asociativo de hash cerrado resultante, con cajones de 3 elementos, para la columna "last_name", suponiendo además que función hash es como sigue: [lenght(last_name) % 3 + 1]
- c-) El índice bitmap resultante, correspondiente a la columna "gender"

Observación: considere que la columna "row_id" corresponde al puntero de dirección física de cada fila.

row_id	email	first_name	last_name	gender	ip_address
1	ol@google.com	Osbert	Lovitt	Male	70.166.89.34
2	vh@uma.com	Vick	Haydock	Male	31.99.104.100
3	kc@wisc.com	Kyrstin	Cranke	Female	196.17.114.77
4	ec@yahoo.com	Ev	Codling	Male	50.31.115.84
5	co@labs.com	Christie	Orbell	Male	130.61.119.154
6	sj@mozilla.org	Sunny	Jurkowski	Male	246.16.196.54
7	dr@goone.jp	Deana	Rizzotto	Female	87.49.64.101
8	ea@google.com	Erick	Aiton	Male	218.12.9.134
9	rf@ow.com	Rici	Ferrieroi	Female	112.56.158.167
10	jp@tripod.com	Jaymie	Phillimore	Male	111.178.156.148
11	gm@yahoo.com	Gedi	Monaghan	Female	55.145.183.5
12	jc@mayo.com	Johnath	Claughton	Female	194.25.32.140
13	rs@forbes.com	Rhianon	Springall	Female	254.21.97.236
14	nm@biglobe.com	Ninnette	McGraith	Female	72.63.106.172
15	kn@wired.com	Kathryn	Needs	Male	87.162.18.200

Explique brevemente en sus términos: Entre los enfoques existentes para el manejo de atributos de dimensión que cambian lentamente (SCD). ¿Cuál es la diferencia entre las técnicas de manejo de cambio del tipo 1 y tipo 2?. Así mismo, cite al menos un ejemplo de aplicación para cada tipo.

Tipo 1 (Sobreescribir)

- -Este tipo es el más básico y sencillo de implementar
- -No guarda los cambios históricos
- -No requiere ningún modelado especial y no necesita que se añadan nuevos registros a la tabla

Este tipo se ocupa de las actualizaciones en la tabla dimensional, para los casos en que la preservación del historial no es una consideración y debe reemplazar los valores antiguos en su tabla con los recientes.

Un ejemplo de uso podría ser un registro pequeño de una empresa con la información de los compradores, ya que al momento de cambiar de número por ejemplo la información vieja ya no nos interesa guardar ni mantener, solo sobreescribirla.

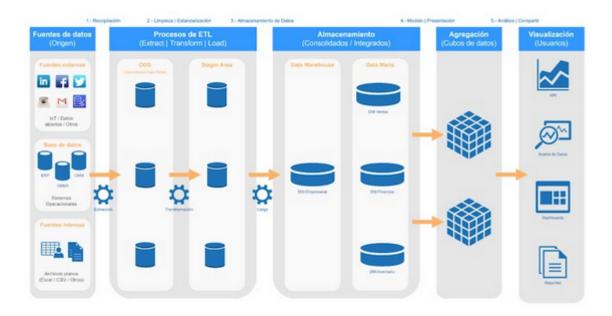
Tipo 2 (Añadir fila)

- Requiere que se agreguen algunas columnas adicionales a la tabla de dimensión que suelen ser fechas y versiones de control.

Este tipo se ocupa de los cambios en su dimensión que deben ser rastreados. Se inserta un nuevo registro con cada cambio, y el registro existente se marca como caducado, por fecha, versión o estado.

Un ejemplo de uso podría ser un programa de gestión de ítems de proyecto en donde te importaría por ejemplos las versiones de cada uno y las fechas de cambio para tener un seguimiento más controlado.

Dado la siguiente arquitectura genérica para una solución Bl. Explique brevemente en sus términos, ¿en qué consisten los siguientes pasos?: 1-) Recopilación. 2-) Limpieza y estandarización. 3-) Almacenamiento de datos. 4-)Análisis y compartir.



- 1)Recopilación: se refiere a los métodos de recopilación de datos dentro de la organización. La arquitectura sostenible reconoce que los datos son importantes para cada departamento de la empresa y donde se originan los datos.
- 2)Limpieza y estandarización: se refiere al filtrado de los datos que puedan considerase como "basura" para poder garantizar la fiabilidad de los mismos.
- 3)Almacenamiento de datos: una vez la información ya fue depurada y consolidada, se almacena en un datawarehouse corporativo.
- 4)Análisis y compartir: con el análisis de los datos es posible la construcción de distinto data marts departamentales para su posterior distribución.

Explique brevemente en sus términos: ¿Por qué se dice que los datos son el nuevo activo de las empresas?. Así mismo, En Data Warehousing, ¿Cuál es la diferencia entre un Data Warehouse empresarial y un Datamart?.

Los datos se han convertido en el activo más importante para las empresas, este es considerado por muchos el recurso más abundante en la actualidad, ya que digamos que cada persona tiene su huella digital, es decir su información personal en algún lugar de internet. Por ello, es que las empresas ven la importancia vital que tienen los datos para mantenerlas competitivas.

Un Data Warehouse es un almacén de datos, recopila y administra datos de diversas fuentes para proporcionar información empresarial significativa. Es un gran depósito de datos que se almacenan y se obtienen de múltiples fuentes. Se verifica, se limpia y entonces se integra con el sistema Data Warehouse.recopilados de diferentes organizaciones o departamentos dentro de una corporación. Los datos almacenados en un Data Warehouse siempre ofrecen más detalle en comparación con los de un Data Mart.

Un Data Mart, en cambio, es un subconjunto único de un Data Warehouse. Está diseñado para satisfacer las necesidades de un determinado grupo de usuarios. Un Data Mart solo obtiene datos de unas pocas fuentes. Un Data mart se centra en un solo tema, mientras que los datos de un Data Warehouse comprende datos de todos los departamentos de la organización donde se actualiza continuamente para eliminar datos redundantes.

Describa la lógica del Algoritmo de Programación Dinámica para la Optimización de Consultas. Indique los costos asintóticos del Algoritmo tanto en complejidad espacial como temporal

Para buscar el mejor árbol de join de n relaciones n Considerar todos los planes de la forma:

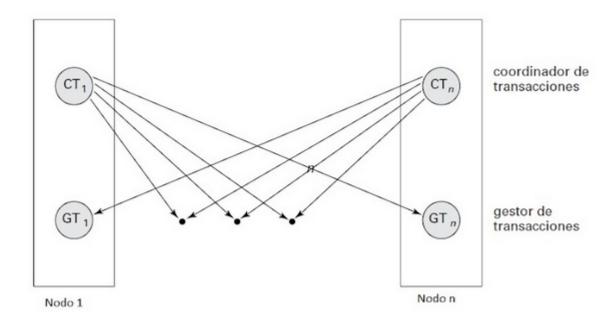
- -S1 (S S1) donde S1 es un subconjunto no vacío de S.
- -Computar recursivamente el costo de cada subconjunto de reunión de S. Escoger la más barata de las 2n 1 alternativas.
- -Caso base de la recursión: acceso a una sola relación. p Utilizar el modo de acceso más apropiado.
- -Cuando se computa el plan para cualquier subconjunto, se guarda el resultado para utilizarlo cuando sea requerido nuevamente, en vez de volver a calcularlo.

La complejidad temporal del algoritmo de P.D. es O(3^n) La complejidad espacial es O(2n)

Explique la importancia de las reglas de equivalencia del algebra relacional desde el punto de vista de la optimización de consultas. Proporcione y explique al menos dos ejemplos de la aplicación de alguna regla de equivalencia en un caso de optimización.

Proporcione un ejemplo gráfico que explique, en sus términos, como se lleva a cabo la detección de interbloqueos en un SGBDD.

Explique en sus términos y en forma esquemática como se lleva a cabo el procesamiento distribuido de transacciones en un SGBDD. Tenga el cuenta el diagrama indicado a continuación.



Gestor de transacciones (GT)

Administra la ejecución de transacciones del sitio.

Cada GT es responsable de mantener un registro histórico y coordinar la ejecución concurrente de transacciones.

Coordinador de transacciones (CT)

Coordina la ejecución de diferentes transacciones iniciadas en el sitio.

Cada CT es responsable de iniciar una transacción, dividir la transacción en varias sub-transacciones y distribuirlo a los diferentes sitios, coordinar la terminación de la transacción.